

국어 영역

[1~4] 다음 글을 읽고 물음에 답하시오.

대규모 언어 모델은 문장을 구성하는 기본 단위인 토큰을 앞에서부터 하나씩 생성한다. 이때 다음 토큰을 정하려면 그 앞의 토큰이 모두 정해져 있어야 하므로, 토큰 하나를 생성할 때마다 모델 전체의 계산을 한 번씩 거쳐야 한다. 따라서 모델이 클수록 토큰을 생성하는 속도가 느려진다. 그런데 큰 모델이 토큰 하나를 새로 생성하는 데 걸리는 시간과, 이미 주어진 토큰 여러 개를 한꺼번에 평가하는 데 걸리는 시간은 크게 다르지 않다. 이미 주어진 토큰 여러 개를 평가할 때는 각 위치의 계산을 동시에 처리할 수 있기 때문이다. 그렇다면 이러한 시간의 차이를 이용하여 토큰을 생성하는 속도를 높일 수는 없을까?

이러한 착안에서 나온 생성 방식이 추측 디코딩이다. 추측 디코딩에서는 먼저 크기가 작은 초안 모델이 토큰 여러 개를 차례로 생성한다. 이렇게 생성된 토큰의 나열을 초안이라 한다. 초안 모델은 크기가 작기 때문에 토큰을 하나씩 생성해도 걸리는 시간이 짧다. 이어서 실제로 출력을 내려는 큰 모델인 목표 모델이 초안 전체를 한 번에 평가한다. 이 평가에서 목표 모델은 초안의 각 위치에서 그 위치의 토큰이 나올 확률을 계산한다. 한편 초안 모델도 초안을 생성하면서 각 위치의 토큰이 나올 확률을 계산해 두므로, 초안의 위치마다 초안 모델의 확률과 목표 모델의 확률이 하나씩 마련된다.

두 확률을 바탕으로 초안의 각 위치의 토큰을 받아들일지 정하는 과정을 검증이라 한다. 검증은 초안의 앞에서부터 한 토큰씩 진행된다. 어떤 위치에서 목표 모델의 확률이 초안 모델의 확률 이상이면 그 위치의 토큰은 수락된다. 목표 모델의 확률이 초안 모델의 확률보다 작으면, 목표 모델의 확률을 초안 모델의 확률로 나눈 값을 확률로 하여 그 위치의 토큰을 수락한다. 어떤 위치의 토큰이 거부되면 그 뒤의 초안 토큰들은 확인되지 않고 모두 버려진다. 이때 거부된 위치에서는 목표 모델이 자신이 계산한 확률 분포에 따라 토큰을 다시 뽑는다. 초안의 토큰이 모두 수락되면 목표 모델은 평가에서 함께 얻은 확률 분포를 이용해 초안 다음 위치의 토큰 하나를 더 뽑는다. 이러한 규칙을 따르면 최종 출력의 확률 분포는 목표 모델이 혼자 토큰을 생성할 때의 확률 분포와 같아진다.

추측 디코딩의 생성 속도는 한 번의 검증으로 얻는 토큰의 수에 달려 있다. 초안의 토큰이 수락되는 비율을 **수락률**이라 할 때, 한 번의 검증으로 얻는 토큰의 수는 수락률이 높을수록 많아진다. 또한 초안의 길이를 늘리면 초안의 토큰이 모두 수락될 때 한 번의 검증으로 얻는 토큰의 수가 많아진다. 그러나 초안의 앞쪽 위치에서 거부가 일어나면 그 뒤의 초안 토큰을 생성하는 데 든 계산은 헛수고가 된다. 수락률은 초안 모델이 계산하는 확률이 목표 모델이 계산하는 확률과 비슷할수록 높다. 일반적으로 초안 모델이 클수록 목표 모델이 계산하는 확률과 비슷한 확률을 계산한다. 하지만 초안 모델이 커질수록 초안을 생성하는 데 걸리는 시간은 늘어난다.

한편 추측 디코딩에서 출력의 품질은 어떤 초안 모델을 사용하든 목표 모델이 혼자 토큰을 생성할 때와 같다. 즉 초안 모델은 생성 속도에만 영향을 준다. 다만 수락률이 매우 낮으면 검증마다 목표 모델이 다시 뽑은 토큰 하나만 얻으면서 초안을 생성하는 데 걸리는 시간은 그대로 더해진다. 이 경우 추측 디코딩의 생성 속도는 목표 모델이 혼자 토큰을 생성할 때보다 오히려 느려진다.

1. 윗글을 읽은 학생의 반응으로 적절하지 않은 것은?


- ① 토큰을 생성하는 속도가 느려지는 원인을 파악한 후, 이를 해결하기 위한 방안이 제시되어 있는지 확인하며 읽었군.
- ② 추측 디코딩이 지닌 한계를 극복하기 위해 제안된 다른 생성 방식의 원리를 파악하며 읽었군.
- ③ 추측 디코딩의 절차를 파악하고, 그 절차에서 적용되는 초안 토큰의 수락 규칙을 확인하며 읽었군.
- ④ 추측 디코딩의 생성 속도를 결정하는 요인들을 파악하고, 요인들 사이의 관계를 확인하며 읽었군.
- ⑤ 추측 디코딩의 장점과 한계를 파악하고, 한계가 발생하는 조건을 확인하며 읽었군.

2. 윗글을 바탕으로 추론한 내용으로 가장 적절한 것은?

- ① 초안의 어떤 위치에서 초안 모델의 확률이 목표 모델의 확률의 두 배이면, 그 위치의 초안 토큰은 반드시 거부되겠군.
- ② 초안의 첫 위치에서 초안 토큰이 거부되면, 그 검증에서는 목표 모델이 새로 뽑은 토큰을 포함해 어떤 토큰도 얻지 못하겠군.
- ③ 초안의 어떤 위치의 초안 토큰이 수락되면, 그 위치 바로 뒤에 놓인 초안 토큰도 검증 없이 함께 수락되겠군.
- ④ 초안의 모든 위치에서 두 모델의 확률이 같으면, 한 번의 검증으로 얻는 토큰의 수는 초안의 길이보다 하나 더 많겠군.
- ⑤ 초안의 모든 위치에서 목표 모델의 확률이 초안 모델의 확률보다 작으면, 최종 출력의 분포는 목표 모델이 혼자 생성할 때와 달라지겠군.

3. **수락률**에 대한 설명으로 적절하지 않은 것은?

- ① 초안을 길게 늘리기만 해도 초안 모델의 확률이 목표 모델의 확률에 가까워지므로 수락률은 높아지겠군.
- ② 초안 모델의 크기를 키우면 수락률이 높아질 수 있지만, 그만큼 초안을 생성하는 데 드는 시간도 늘어나겠군.
- ③ 수락률이 높아지더라도 그것이 최종 출력의 품질을 목표 모델이 혼자 생성할 때보다 높여 주지는 않겠군.
- ④ 수락률이 매우 낮은 초안 모델을 쓰면, 초안 생성에 든 시간만큼 목표 모델 단독 생성보다 속도 면에서 손해를 보겠군.



- ⑤ 수락률이 낮을수록 초안 앞쪽에서 거부가 일어나기 쉬워, 뒤쪽 초안 토큰을 만든 계산이 버려질 가능성이 커지겠군.

4. 윗글을 읽고 <보기>에 대해 보인 반응으로 적절하지 않은 것은?

<보기>

연구자는 같은 목표 모델을 사용하되 초안 모델의 크기와 초안의 길이를 달리하는 세 시스템 A, B, C를 구성하고, 각 시스템의 생성 속도와 출력의 품질을 비교하는 실험을 수행하였다. 시스템 A는 크기가 작은 초안 모델과 길이가 짧은 초안을 사용하고, 시스템 B는 크기가 작은 초안 모델과 길이가 긴 초안을 사용하며, 시스템 C는 크기가 큰 초안 모델과 길이가 짧은 초안을 사용한다. 실험 결과, 시스템 A와 B의 수락률은 같았고, 시스템 C의 수락률은 시스템 A의 수락률보다 높았다. 또한 시스템 A에서는 초안의 앞쪽 위치에서 거부가 일어나는 경우가 많았고, 시스템 B에서는 초안의 뒤쪽 위치에서 거부가 일어나는 경우가 많았다.

- ① 시스템 B는 초안이 길고 거부가 주로 뒤쪽에서 일어나므로, 시스템 A보다 한 번의 검증으로 얻는 토큰이 많을 수 있겠군.
- ② 시스템 C는 초안 모델의 확률이 목표 모델과 더 비슷하여, 시스템 A보다 한 번의 검증으로 얻는 토큰이 많을 수 있겠군.
- ③ 시스템 C는 시스템 A보다 수락률이 높으므로, 시스템 C의 출력의 품질도 시스템 A의 출력의 품질보다 높겠군.
- ④ 시스템 B는 시스템 A와 같은 크기의 초안 모델로 더 긴 초안을 만들므로, 초안을 생성하는 데 걸리는 시간이 더 길겠군.
- ⑤ 시스템 C는 시스템 A보다 초안 생성에 시간이 더 걸리므로, 높은 수락률이 반드시 더 빠른 생성 속도로 이어지지 않는겠군.

