

국어 영역

[1~4] 다음 글을 읽고 물음에 답하시오.

언어 모델은 문장을 생성할 때 문장의 최소 단위인 토큰을 하나씩 생성한다. 이때 언어 모델은 새로운 토큰을 생성할 때마다 그 이전에 생성한 모든 토큰을 ㉠ 참고한다. 이러한 생성 방식을 자기회귀 생성이라 한다. 자기회귀 생성에서는 새 토큰을 하나 생성할 때마다 그 이전에 생성한 토큰의 수가 하나씩 늘어난다. 따라서 생성된 문장이 길어질수록 새 토큰을 생성할 때 참고해야 할 토큰의 수가 많아진다. 또한 새 토큰을 생성할 때 그 이전에 생성한 모든 토큰을 참고해야 하므로, 한 토큰을 생성할 때마다 이전 단계에서 참고한 토큰을 다시 참고하게 된다.

언어 모델은 어텐션을 사용하여 새 토큰을 생성할 때 앞 토큰들을 참고한다. 어텐션에서는 먼저 각 토큰을 질의, 키, 값이라는 세 가지 수의 묶음으로 ㉡ 변환한다. 그다음 새 토큰의 질의와 앞 토큰들의 키를 각각 비교하여 두 수가 유사한 정도를 구한다. 이때 어떤 토큰의 키와 값은 그 토큰 이전에 생성된 토큰들만을 참고하여 구해진다. 따라서 어떤 토큰의 키와 값은 그 토큰 이후에 토큰이 추가되어도 바뀌지 않는다. 한편 앞 토큰들 가운데 새 토큰의 질의와 키가 유사한 정도가 큰 토큰일수록, 그 토큰의 값이 더 크게 반영되도록 앞 토큰들의 값을 ㉢ 섞은 수를 구한다. 그리고 이 수를 바탕으로 다음 토큰이 결정된다.

자기회귀 생성에서는 한 토큰을 생성할 때마다 앞 토큰들의 키와 값을 다시 구해야 한다. 이러한 중복되는 계산 과정은 생성 과정의 효율을 떨어뜨린다. 이러한 문제를 해결하기 위해 ㉣ 앞 토큰들의 키와 값을 미리 구하여 메모리에 저장해 두었다가 다음 단계에서 다시 쓰는 방식인 KV 캐시가 사용된다. KV 캐시에서는 새 토큰을 생성할 때마다 새 토큰의 질의, 키, 값만을 계산하고, 새로 구한 키와 값만을 메모리에 저장한다. 이때 앞 토큰들의 질의는 그 이후의 단계에서 다시 쓰이지 않으므로 메모리에 저장하지 않는다. 한편 KV 캐시에서는 캐시가 차지하는 저장 공간의 크기가 생성한 토큰의 수에 비례하여 커진다. 또한 캐시는 요청마다 따로 만들어지므로, 저장 공간의 크기는 동시에 처리하는 요청의 수에도 비례하여 커진다.

KV 캐시를 사용하면 한 토큰을 생성하는 데 걸리는 시간에서 계산에 걸리는 시간이 차지하는 비중은 작아진다. 그러나 KV 캐시를 사용하면 한 토큰을 생성할 때마다 메모리에 저장된 모든 앞 토큰들의 키와 값을 읽어 와야 한다. 따라서 KV 캐시를 사용하면 한 토큰을 생성하는 데 걸리는 시간은 메모리에서 저장된 수를 읽어 오는 데 걸리는 시간에 좌우된다. 이처럼 전체 처리 속도를 ㉤ 제한하는 구간을 병목이라 한다. KV 캐시를 사용하지 않을 때는 병목이 계산 과정에 있지만, KV 캐시를 사용하면 병목이 메모리에서 저장된 수를 읽어 오는 과정으로 이동한다. 이때 메모리에서 저장된 수를 읽어 오는 데 걸리는 시간은 캐시가 차지하는 저장 공간의 크기에 비례하여 길어진다. 또한 메모리의 용량은

정해져 있으므로, 캐시가 차지하는 저장 공간의 크기가 커질수록 동시에 처리할 수 있는 요청의 수는 작아진다.


언어 모델은 어텐션을 여러 관점에서 나란히 수행하는데, 이때 각 관점에서 수행되는 어텐션의 단위를 헤드라 한다. 본래는 헤드마다 질의, 키, 값을 따로 두므로, KV 캐시에서는 앞 토큰들의 키와 값을 저장할 때 헤드마다의 키와 값이 따로 저장된다. 그러나 그룹 질의 어텐션에서는 헤드들을 몇 개의 그룹으로 묶고, 같은 그룹에 속한 헤드들이 하나의 키와 값을 ㉥ 공유하게 한다. 따라서 그룹 질의 어텐션에서는 한 그룹에 묶이는 헤드의 수가 많을수록 캐시가 차지하는 저장 공간의 크기가 작아진다. 그러나 같은 그룹에 속한 헤드들이 같은 키와 값을 참고하므로, 한 그룹에 묶이는 헤드의 수가 많을수록 헤드마다 서로 다른 정보를 참고하는 능력은 줄어든다. 다만 그룹 질의 어텐션에서는 질의를 헤드마다 따로 두기 때문에, 같은 그룹에 속한 헤드들이 같은 키와 값을 참고하더라도 각 헤드마다 앞 토큰들의 값을 반영하는 정도는 달라질 수 있다.

1. 윗글을 읽고 답을 찾을 수 있는 질문으로 적절하지 않은 것은?

- ① 자기회귀 생성에서 캐시를 쓰지 않으면 같은 앞 토큰의 키와 값을 단계마다 거듭 구하게 되는 까닭은 무엇인가?
- ② KV 캐시가 차지하는 저장 공간이 동시에 처리하는 요청이 늘어날수록 함께 커지는 까닭은 무엇인가?
- ③ 어텐션에서 새 토큰의 질의와 앞 토큰의 키가 닮은 정도는 구체적으로 어떤 연산을 거쳐 산출되는가?
- ④ KV 캐시를 쓰면 생성 속도를 좌우하는 구간이 계산에서 메모리 읽기로 옮겨 가는 까닭은 무엇인가?
- ⑤ 그룹 질의 어텐션에서 키와 값을 공유하는 헤드끼리도 앞 토큰들을 반영하는 비중이 다를 수 있는 까닭은 무엇인가?

2. ㉣이 가능한 이유로 가장 적절한 것은?

- ① 앞 토큰의 키와 값은 그보다 먼저 생성된 토큰들만으로 정해져 뒤 단계에서도 그대로 쓸 수 있고, 질의는 그 토큰을 생성하는 단계에서만 쓰이기 때문이다.
- ② 새 토큰의 질의와 앞 토큰들의 키가 유사한 정도는 한 번 구하면 이후에도 유지되므로, 앞 토큰들의 값을 섞은 결과를 그대로 다시 쓸 수 있기 때문이다.
- ③ 같은 그룹에 속한 헤드들이 키와 값을 함께 쓰므로, 앞 토큰들의 키와 값을 헤드마다 따로 계산하지 않아도 되는 구조를 갖추고 있기 때문이다.
- ④ 생성 시간이 메모리에서 수를 읽어 오는 데 좌우되므로, 앞 토큰들의 키와 값을 단계마다 다시 계산해도 처리 속도에는 차이가 없기 때문이다.
- ⑤ 새 토큰의 질의는 앞 토큰들의 질의를 참고하여 구해지므로, 앞 토큰들의 질의를 키와 값과 함께 보관해 두어야 다음 단계를 진행할 수 있기 때문이다.



3. 밑글을 바탕으로 <보기>를 이해한 내용으로 적절하지 않은 것은?

————— <보기> —————

A 회사는 자기회귀 생성을 수행하는 언어 모델 ㉠, ㉡, ㉢를 메모리 용량이 같은 컴퓨터에서 각각 운용하고 있다. 세 모델은 모두 64개의 헤드를 두고 KV 캐시를 사용하며, 헤드를 묶는 방식을 제외한 다른 조건은 모두 같다. ㉠은 64개의 헤드를 16개의 그룹으로, ㉡는 64개의 헤드를 4개의 그룹으로 묶는 그룹 질의 어텐션을 사용하고, ㉢는 그룹 질의 어텐션을 사용하지 않는다. 현재 세 모델은 같은 수의 요청을 동시에 처리하면서 각 요청마다 같은 수의 토큰을 생성하고 있다.

- ① ㉠과 ㉡가 같은 수의 토큰을 생성한 시점에서는, 한 그룹에 묶인 헤드가 적은 ㉠의 캐시가 더 큰 공간을 차지하겠군.
- ② ㉢가 지금처럼 ㉡와 같은 수의 요청을 동시에 처리하는 한, 같은 길이의 문장을 생성할 때 캐시가 차지하는 공간은 ㉢가 ㉡보다 크겠군.
- ③ ㉡는 ㉠보다 캐시가 차지하는 공간을 줄일 수 있는 대신, 헤드마다 서로 다른 정보를 참고하는 능력은 ㉠보다 떨어지겠군.
- ④ ㉡와 ㉢ 모두 생성한 토큰이 늘수록 한 토큰을 생성하는 시간이 길어지겠지만, 같은 시점에서 비교하면 ㉡가 ㉢보다 한 토큰을 더 빨리 생성하겠군.
- ⑤ ㉠은 ㉢보다 요청 하나에 대해 메모리에 쌓이는 캐시가 커서, 같은 용량의 메모리로 동시에 처리할 수 있는 요청의 수가 ㉢보다 적겠군.

4. 문맥상 ㉠~㉢와 바꿔 쓰기에 적절하지 않은 것은?

- ① ㉠ : 참조한다
- ② ㉡ : 환원한다
- ③ ㉢ : 혼합한
- ④ ㉠ : 제약하는
- ⑤ ㉢ : 함께 쓰게

